はじめに ― 荒川裕二の技術記事から

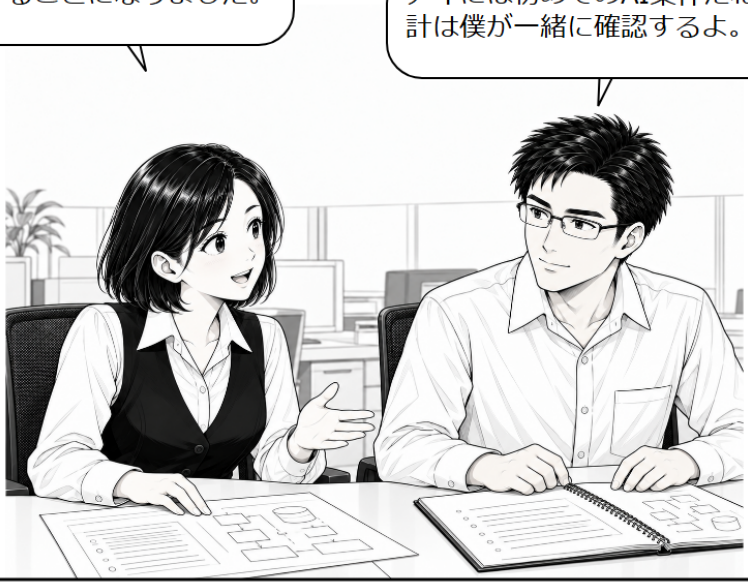

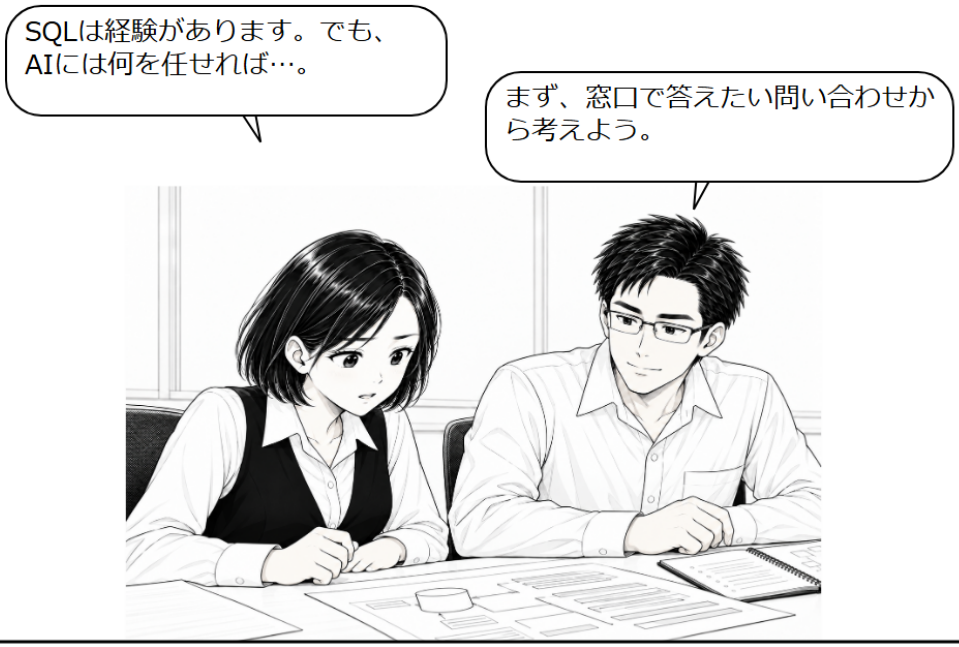

想定する問い合わせ

DEV001のサーバーで管理画面が開きません。
確認手順を知りたいです。

現地保守も頼めますか？

手順の根拠と、訪問できる条件を確認したいんですね。

社内の最新手順と、この機器の契約が必要だね。

問い合わせへの対応案

アイ
訪問の自動予約は今回のスコープ外です。次の機能拡張で対応予定です。

1. 文書の意味検索と業務データの照会を組み合わせる

手順を探す問いと、契約の条件を確かめる問いだね。

手順は文章。契約は顧客や機器ごとの表ですね。

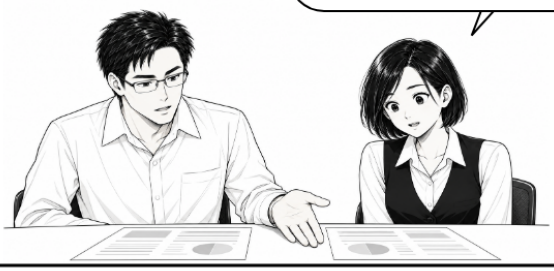

手順書：非構造化データ　　契約表：構造化データ

神宮寺
文書は意味の近さで探す。契約は表の値を条件と照合する。

ベクトル検索とリレーショナル表の検索を、組み合わせるんですね。

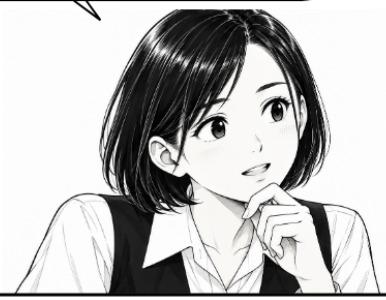

「開かない」「固まった」「応答しない」。言い方が違っても探したい。

文字の一致だけでなく、意味の近さも使うんですね。

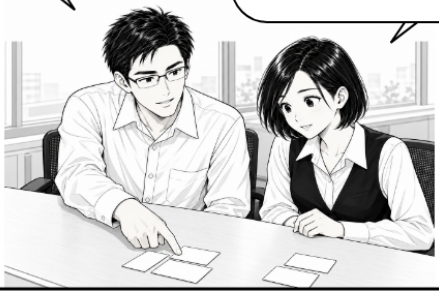

でも、契約の判定が毎回揺らいだら困るよね。

同じ条件なら、いつも同じ結果にしたいです。

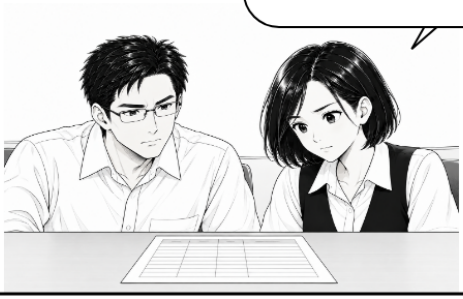

神宮寺
状態・期間・サービス範囲を、いつも同じ基準で確かめたい。

アイ
判定方法も、後でしっかり設計します。

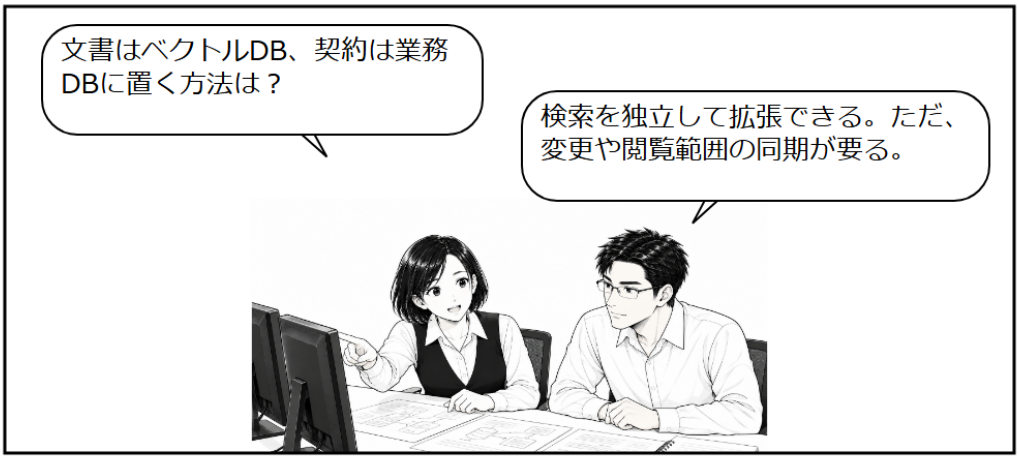

複製の更新が遅れると

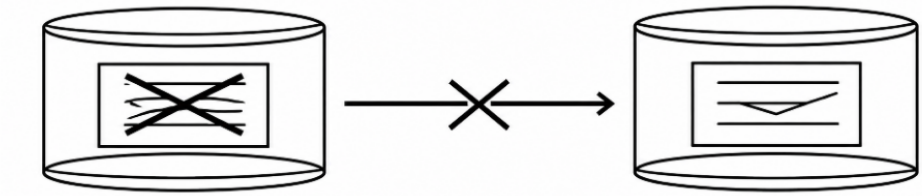

業務DB：取消済み　　検索用の複製：未反映

アイ
解約や公開取消が伝わらなければ、案内を間違えますね。

Oracle AI Databaseなら、
業務表とベクトルを同じDBで扱える。

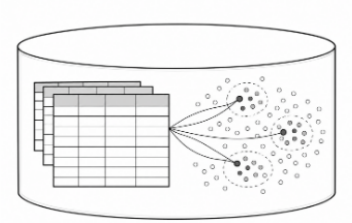

アイ
JOINやEXISTSを使えば、検索用タグへ複製しなくても、業務表の条件を使えるんですね。

鉄道会社を想定した分析例

表と文書に、位置情報も加えられる。鉄道会社を例に見てみよう。

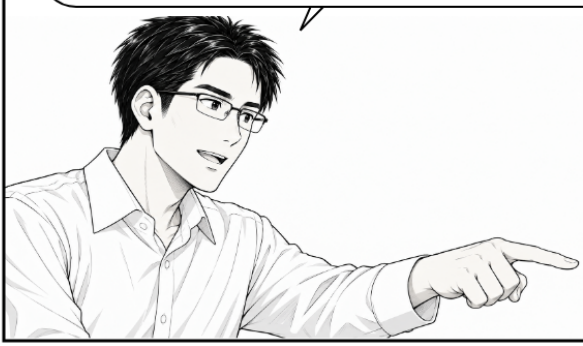

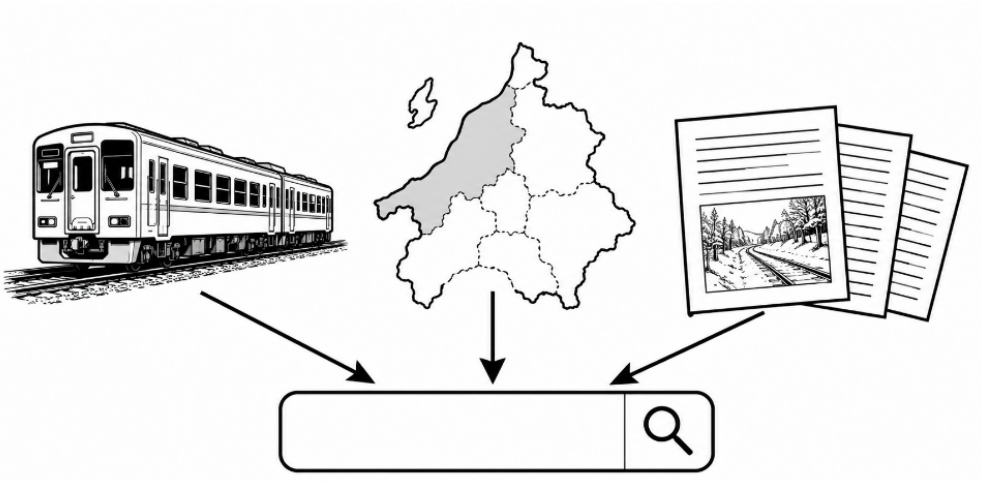

車両タイプと期間　　新潟県への進入　　報告の本文と意味

神宮寺
報告は「ブレーキ」か「制動機」を含むものに絞り、凍結トラブルに意味が近い記述を探す。

表・地理空間・全文検索・ベクトル検索を、SQLで組み合わせるんですね。

閲覧制限や現地対応判断には最新の契約情報を使いたいですね。

今回はOracle AI Databaseを選びます。

本文を変えたらベクトルも更新する。権限の設計も必要だよ。

整合性は私たちの仕事。次はベクトルの作り方ですね。

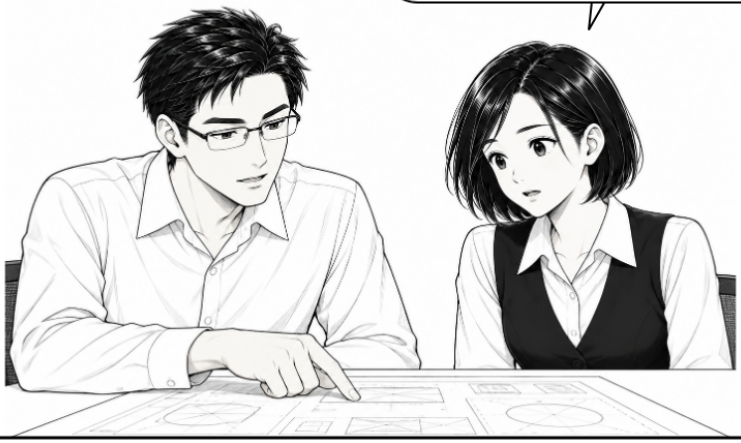

2. 埋め込みモデルをDB内へ持ち込み、DBの中でベクトルを作る

文書をベクトルにするには、何を使うんですか？

埋め込みモデルだよ。文書と質問を同じモデルで変換する。

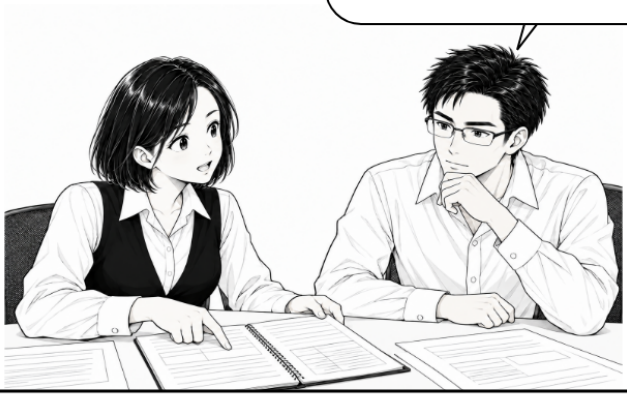

埋め込みモデルとベクトル検索

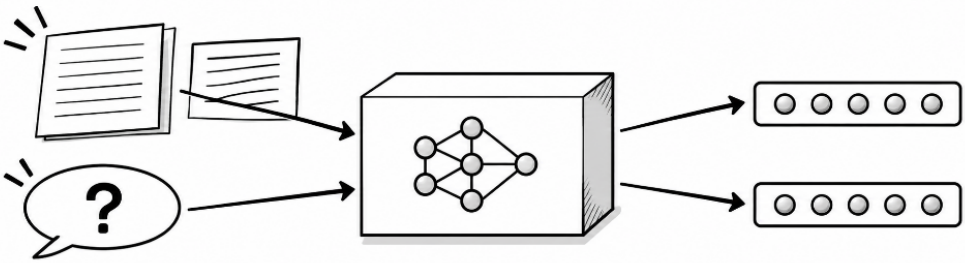

アイ
質問文のベクトルに距離が近いベクトルを持つ文書を見つけるのがベクトル検索ですね

埋め込みモデルは
クラウドのAPIを使うんですか？

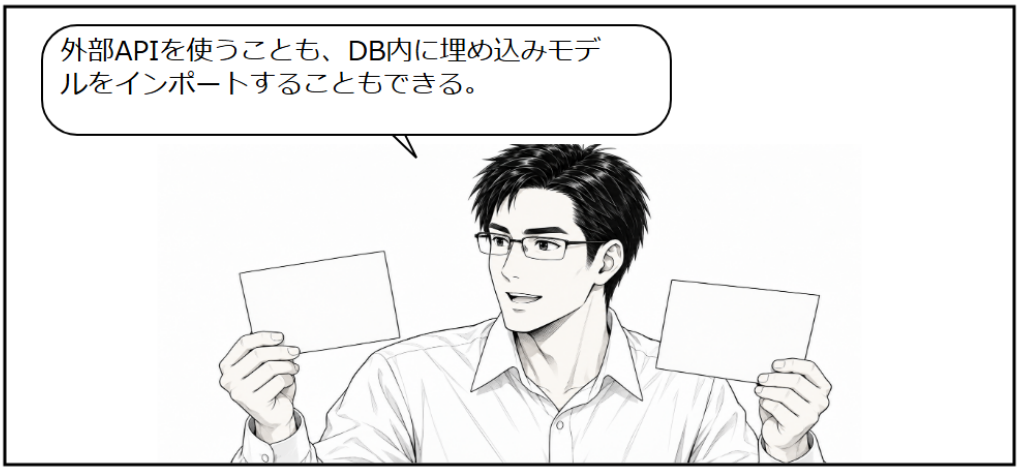
外部APIを使うことも、DB内に埋め込みモデルをインポートすることもできる。

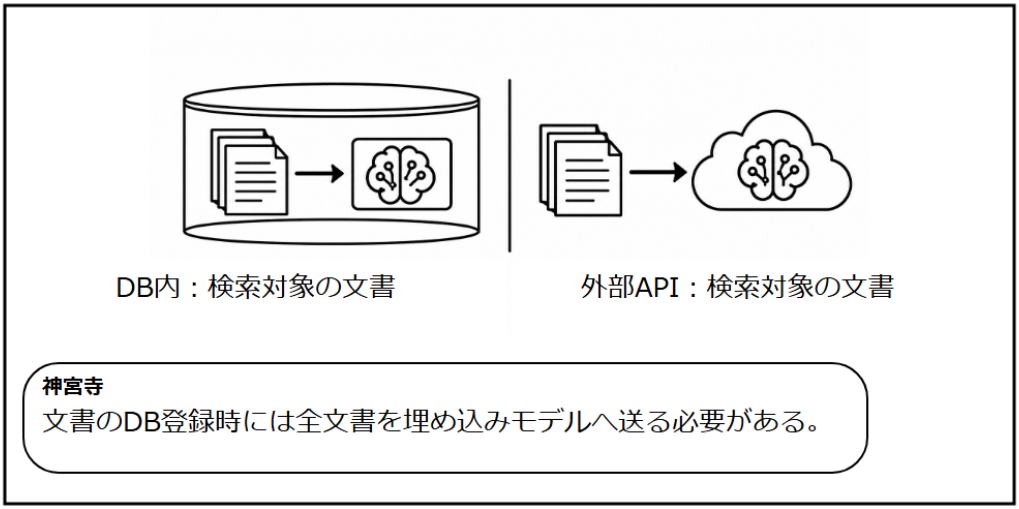
DB内：検索対象の文書
外部API：検索対象の文書
神宮寺
文書のDB登録時には全文書を埋め込みモデルへ送る必要がある。

今回は、検索準備で社内文書の全量を外へ送りたくない。DB内が合いそうです。

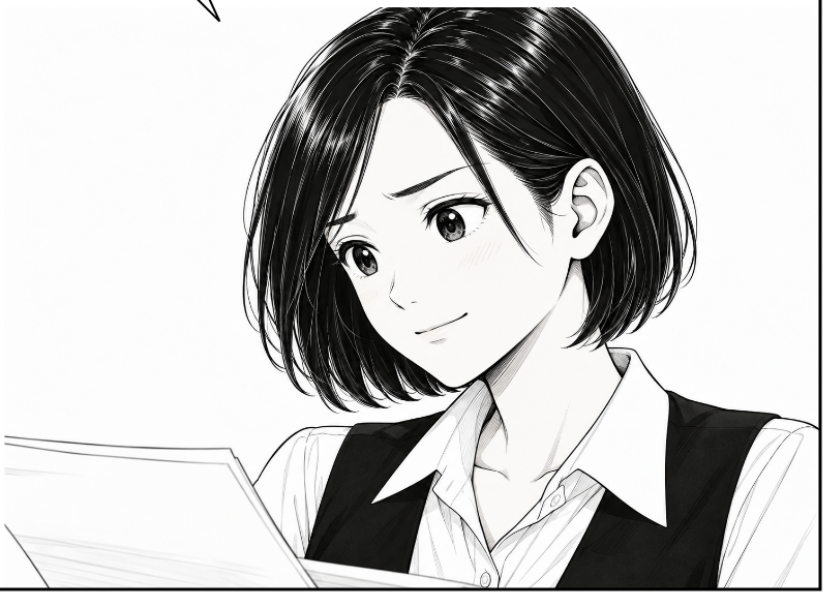

ベクトル変換の速度やＤＢ負荷や同時実行数はしっかり検証しよう。

埋め込みモデルはＤＢ内、回答生成LLMはクラウドAPI

場面	埋め込みモデルへ渡すデータ	LLM へ渡すデータ
初回の埋め込み生成	検索対象文書の全チャンク	なし
文書の追加・改訂	追加・変更したチャンク	なし
質問の埋め込み生成	質問文	なし
RAGの回答生成	なし	質問と取得した文書抜粋

必要な抜粋の送信は許可されています。埋め込みはDB内にします。

モデルの品質・利用条件と、DB資源も確認しよう。

multilingual-e5-large

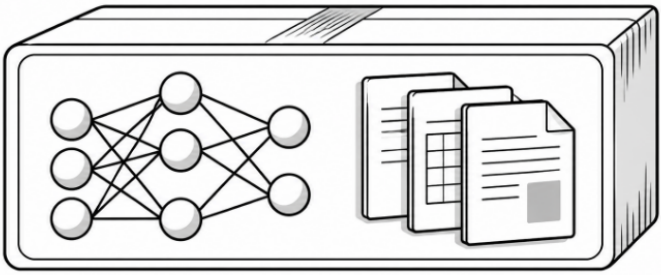

神宮寺
日本語対応の著名なOSS埋め込みモデルの
multilingual-e5-large を
試してみてはどうかな。

神宮寺
ＤＢにインポートするにはこれを ONNX形式に変換しておく

埋め込みモデルのインポート

必要なファイル一式

Object Storage

DBへロード

神宮寺
認証と権限を準備してロードする。付属ファイルも忘れずに。

これで質問文に似ている文書の検索は解決ですね？

では、似ている文書を見つければ案内に使えるかな？

3. チケットの顧客と機種を絞ってベクトル検索する

設計の検証ケース：意味だけで検索

「管理画面が開かない」に近い文章なら、候補は見つかりそうです。

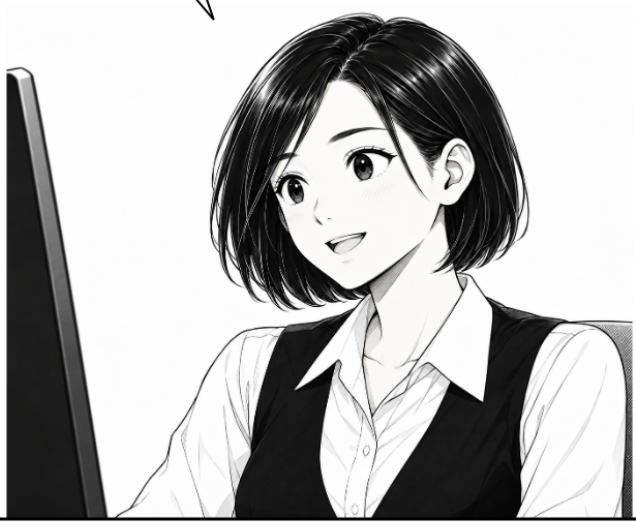

対象AX-100／候補に別機種BX-200・廃止済み文書

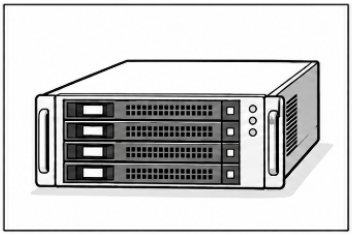

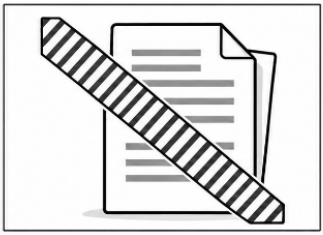

アイ
あっ、別機種。それに廃止済み。これでは案内に使えません。

チケットから対象をたどる

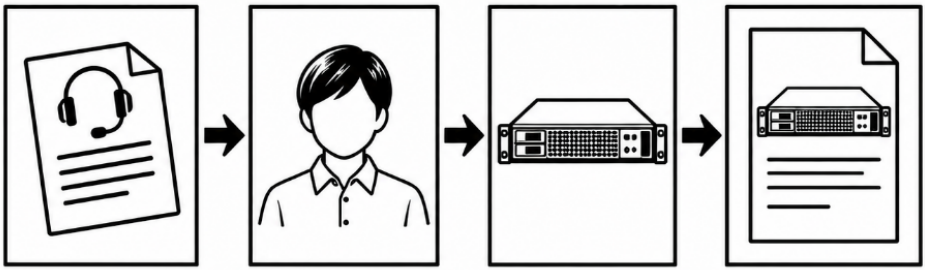

チケット SR001	顧客 C001	機器 DEV001	機種 AX-100

神宮寺
チケットから顧客を特定し、その顧客の台帳で機器と機種を調べる。

閲覧範囲・機種・公開状態で絞り、その中を距離順に。業務表が効きますね。

選択中の顧客だけを返すビューにする。未選択ならゼロ件だ。

担当者がそのチケットを扱えるかの認可は、別に必要ですね。

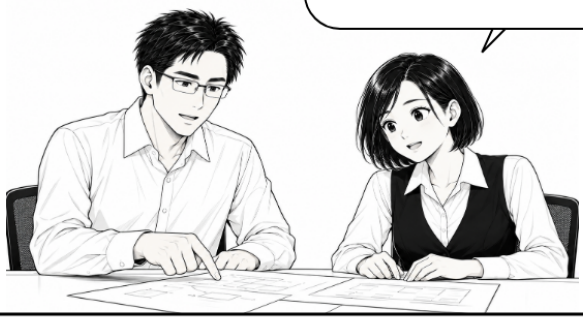

契約が無効なら、文書も出しませんか？

許可された技術文書は案内できる。現地保守の可否とは別だよ。

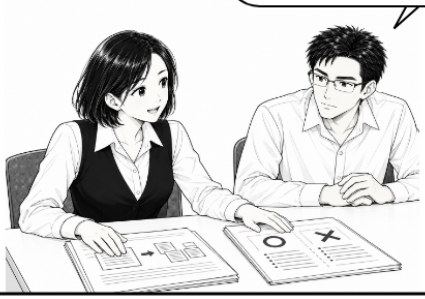

今どの顧客を担当しているか、DBはどう見分けるんですか？

選んだチケットと顧客IDを、この接続の中に保持するんだ。

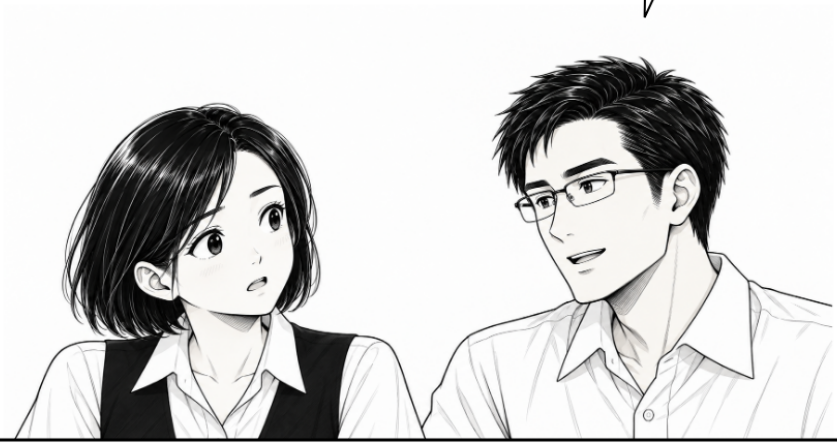

接続に残した顧客情報の後始末

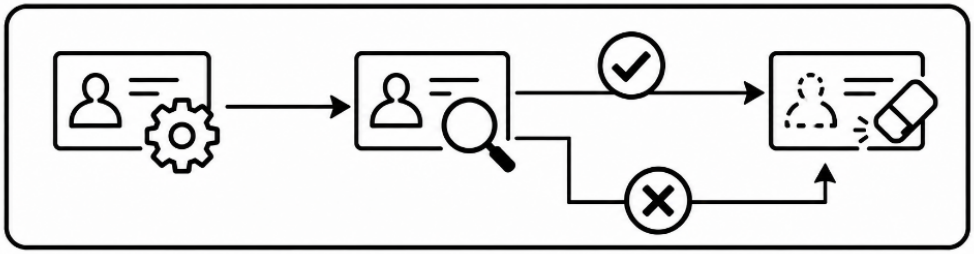

顧客を設定　　同じ接続で照会　　必ず消去

神宮寺
正常終了でも失敗でも消去する。顧客の状態を次の依頼へ残さない。

別顧客・別機種・未選択をテストします。認可と状態の後始末も。

文書を探す設計はできました。次は、担当者が使える回答にしたいです。

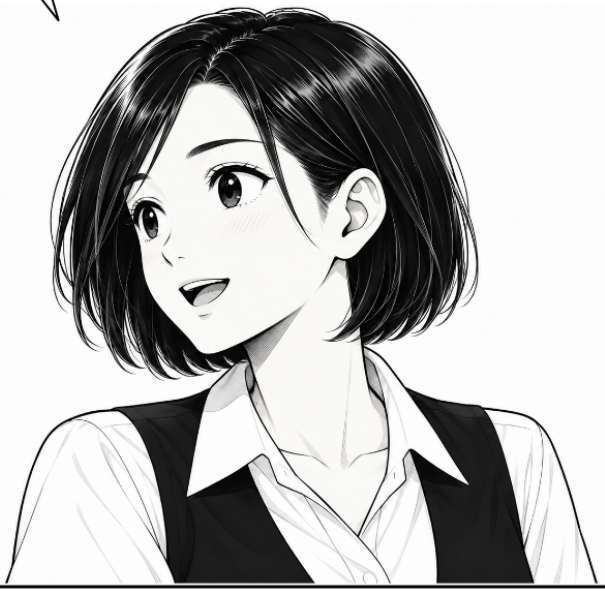

4. 検索した文書を根拠にRAG（検索拡張生成）で回答する

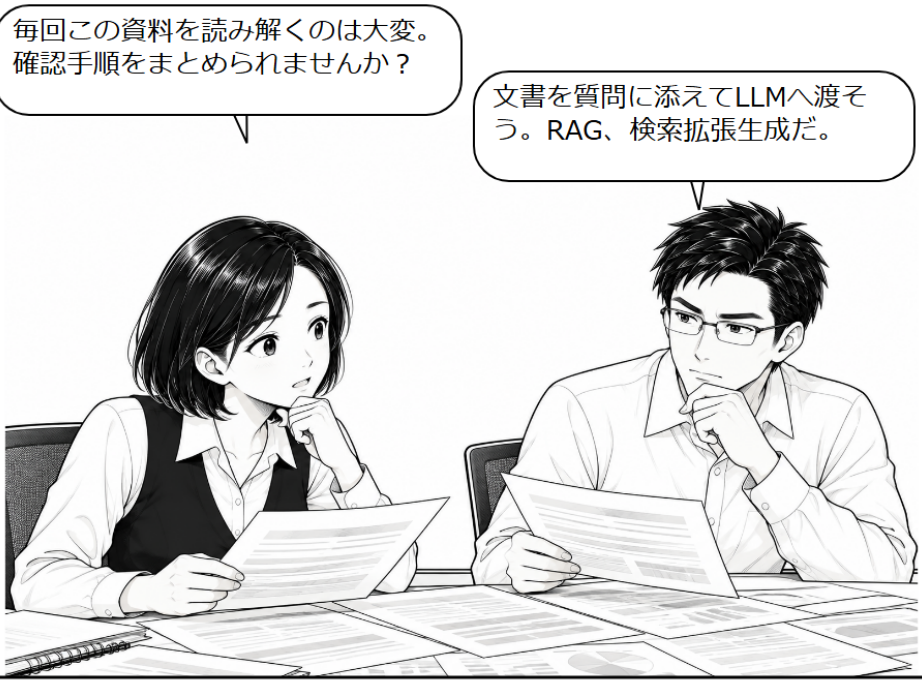

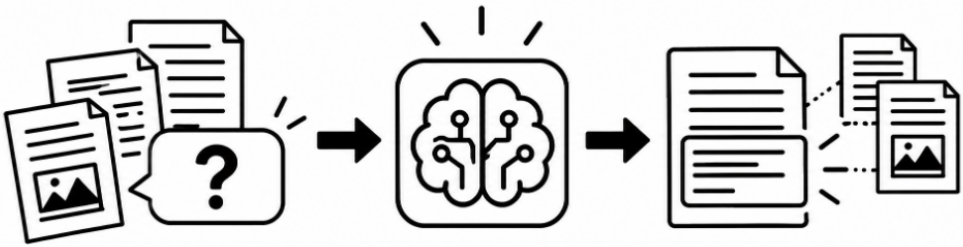

アイ
今回案内できる文書を、回答の根拠にするんですね。

このRAGでは検索・生成・検査の順を
PL/SQLで固定する。
処理選択はAIに任せない。

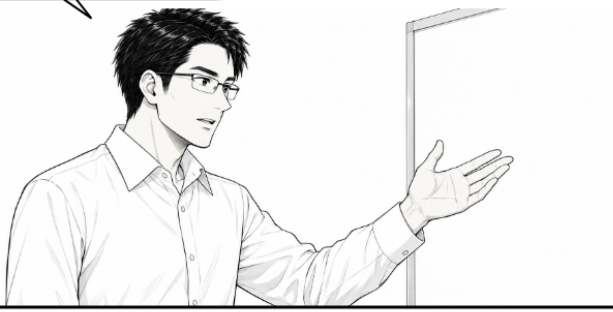

KB001：電源・LAN・疎通を確認、ログを保存

神宮寺
影響を確かめずに再起動しない、という注意も大切だね。

右の用紙KB012：顧客内の運用責任者へ連絡。
訪問は契約と承認を確認

アイ
取得本文と、回答の文書ID・引用を照合します。

引用が原文にあっても、回答の意味まで正しいとは限りませんね。

そう。無関係な引用や、本文を超えた断定を確かめよう。根拠がない場合もね。

根拠不足①：候補がない

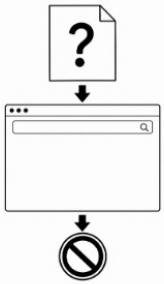

神宮寺
記事のこの例はE999の文字列でも絞ると候補ゼロ。LLMを呼ばず、根拠不足を返す。

根拠不足②：文書はあるが、保証延長の金額がない

神宮寺
検索できても、質問への答えが載っているとは限らない。

分からない答えは作らない。候補ゼロと、答えの記載なしを別々に試します。

固定順のRAGを採用します。検索の成否と、回答が根拠に沿うかを分けて評価します。

残った「現地保守を頼めるか」は？

契約ですね。自然な言葉で、対象機器の一覧も聞けるようにしたいです。

5. NL2SQL で契約情報を照会する

「この顧客の現地保守対象機器を一覧にして」のような質問ができるようにしたいです。
NL2SQLの出番ですか？

Oracleには、Select AIという
NL2SQL機能があるから検討してみよう。

現地保守の対象って、契約がACTIVEならいいんですか？

状態だけでは足りない。期間とサービス範囲も確かめよう。

三つの条件をプロンプトに書いて、LLMに判定してもらえばよさそうですね。

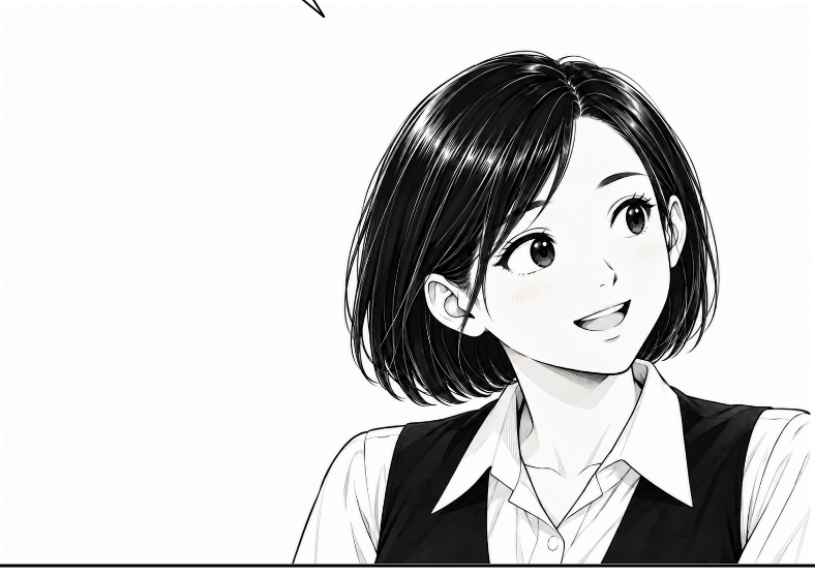

LLMの判断は揺れることがある。同じ条件でも、同じ答えになるとは限らない。

契約の可否が毎回変わったら困りますね。

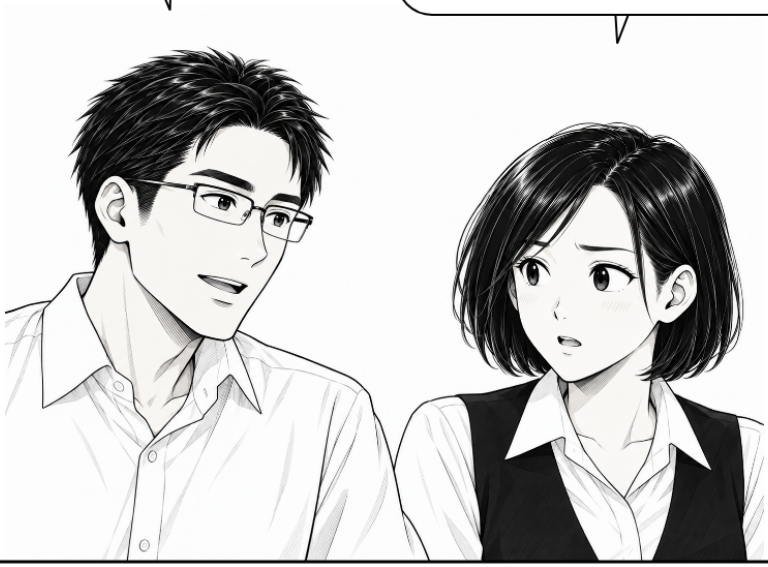

現地保守の対象となる三条件

ACTIVE AND 開始日≦今日の日付≦終了日 AND
ONSITE

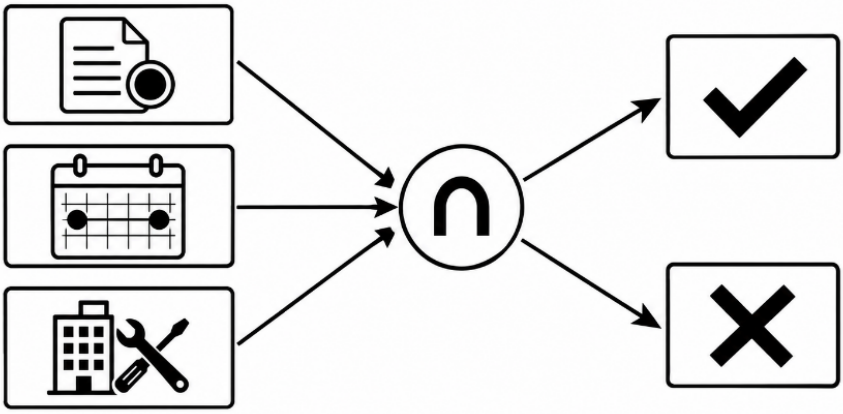

カレンダー：今日の日付が有効期間内か

アイ
それなら、三条件をANDで結ぶ論理式にします。ビューのCASE式で判定列を作れますね。

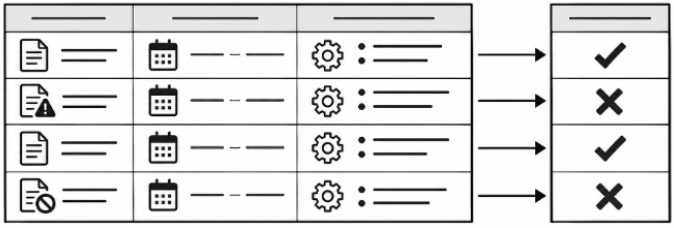

神宮寺
契約データと今日の日付が同じなら、判定結果も同じになる。

アイ
AIはルールを推論せず、判定済みの列を使うんですね。

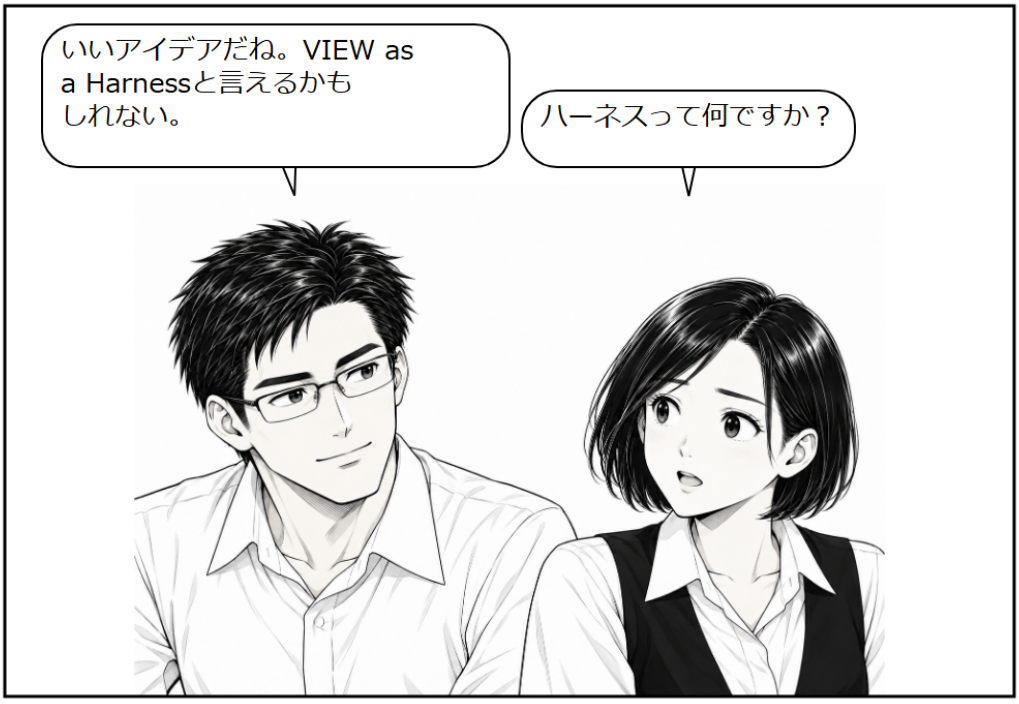
いいアイデアだね。VIEW as a Harnessと言えるかもしれない。
ハーネスって何ですか？

LLMの外側で、使えるデータや道具、実行の進め方を制御する仕組みだよ。
AIへのお願いだけで、守らせようとしないんですね。

ビューが担うハーネス

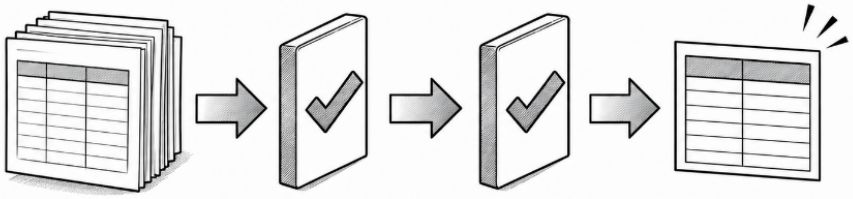

契約の業務表　顧客の範囲　CASE判定　判定済みの列

神宮寺
ビューはハーネスの一部。
ツールの実行や結果の検査は、別のコードで制御する。

アイの試作テスト

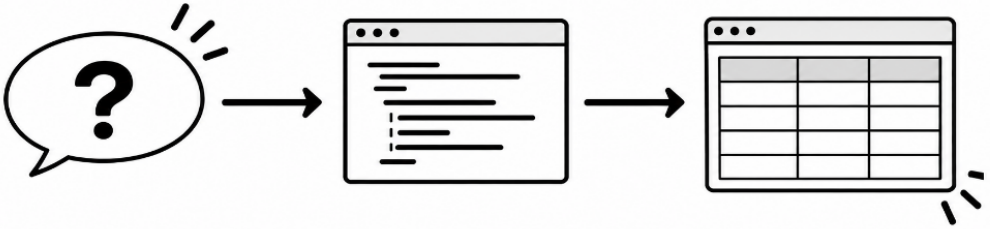

自然言語の質問　SHOWSQLで生成 SQLを表示　確認して実行・ 結果照合

神宮寺
まずSQLを見る。その後、実行した結果を正解と比べよう。

参照先を制限する前の試作

顧客のWHERE条件も誤り

Select AIには、参照先の制限や注釈など、生成を改善する手段がある。

さっきのビューと組み合わせよう。顧客の範囲と契約判定はDBで守るんだ。

許可したビューだけを使う設定にします。列の意味も伝えられますか？

列の意味は注釈で伝えられる。直したSQLを例にするFeedbackも使える。

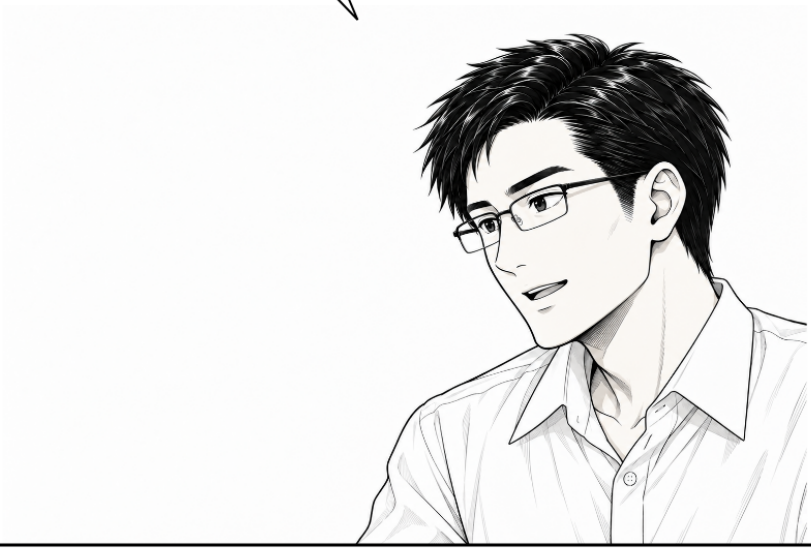

期待する結果と照合

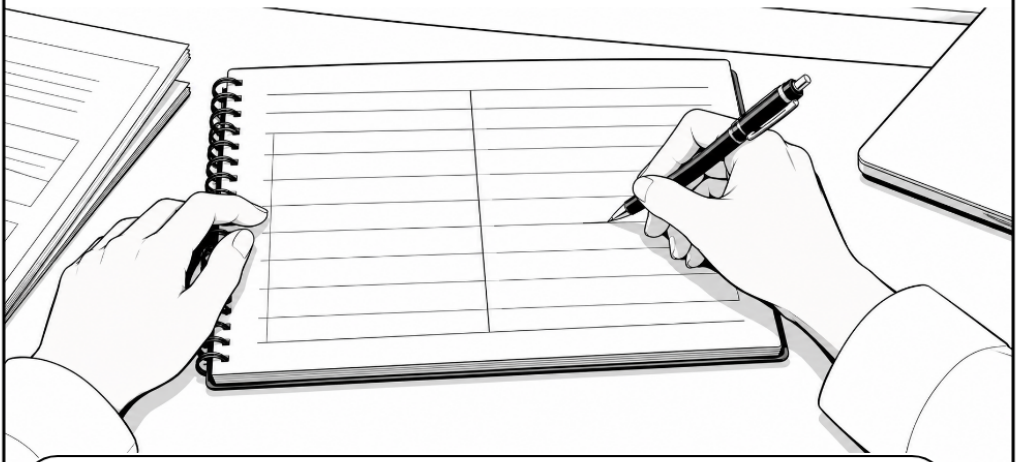

アイ
対象顧客だけになりました。期限切れと現地保守なしも対象外。今回のテストは期待どおりです。

注釈は権限の代わりにはならない。ビューの実行権限と、担当者の認可もそろえよう。

自然な言葉の質問と、DBで守る条件。役割を分けて設計できました。
では、手順と契約を一度に聞かれたら？

6. 文書検索と契約照会をAgentのツールにする

手順だけ、契約だけ、両方。依頼に合わせて処理を選びたいです。

Agentなら、目的に応じてLLMが道具を選び、結果を見て次の処理を考える。

道具って、システムに用意する処理のことですか？

そう。Agentが呼び出せる形にした処理を、ツールと呼ぶ。

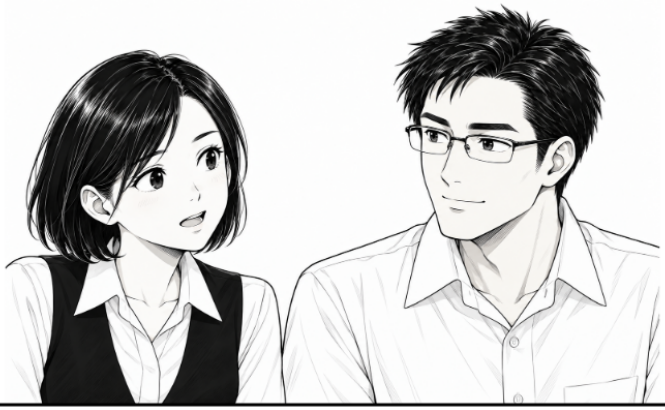

NL2SQLとの関係も整理したいです。

まずはAgentを理解するため、固定SQLの二つのツールで試そう。

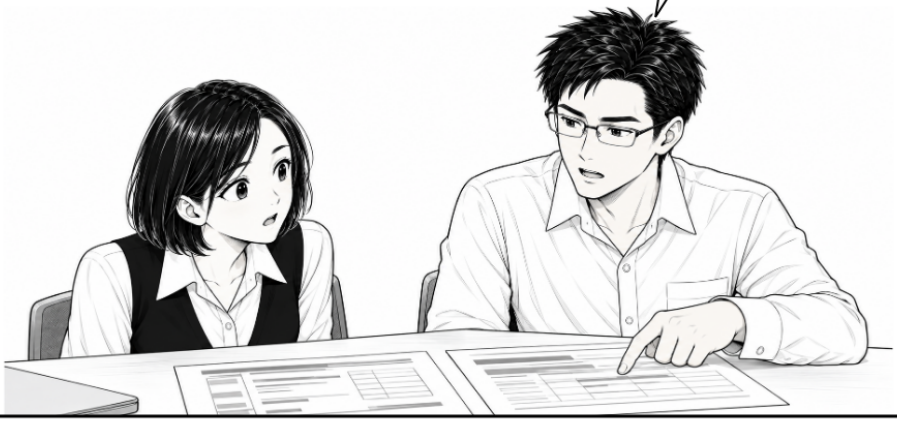

固定SQLを実行する二つのツール

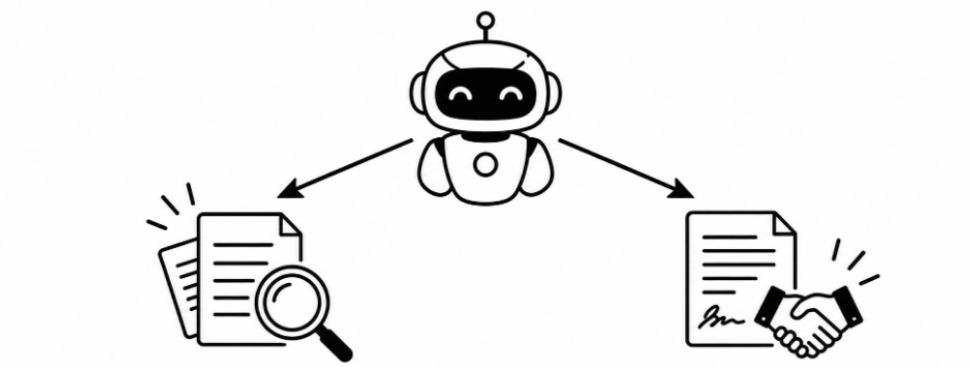

文書検索：条件で絞って距離順

契約照会：ビューの判定列を読む

神宮寺

ここでは毎回SQLを生成しない。
道具をどう呼び、結果を使うかに集中しよう。

なるほど。先ほどのNL2SQLと切り分けると、Agentの働きが見えますね。

このAgentを動かす基盤は、どこに置くんですか？

DB内でAgentを実行できるSelect AI Agentを使ってみよう。

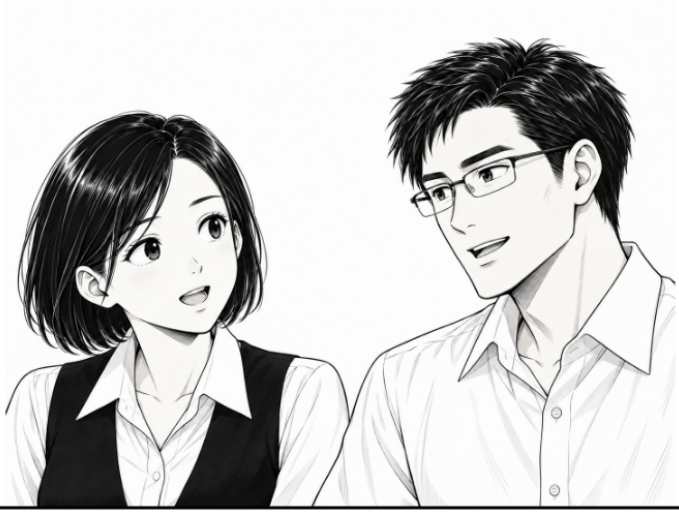

Select AI Agentの実行基盤

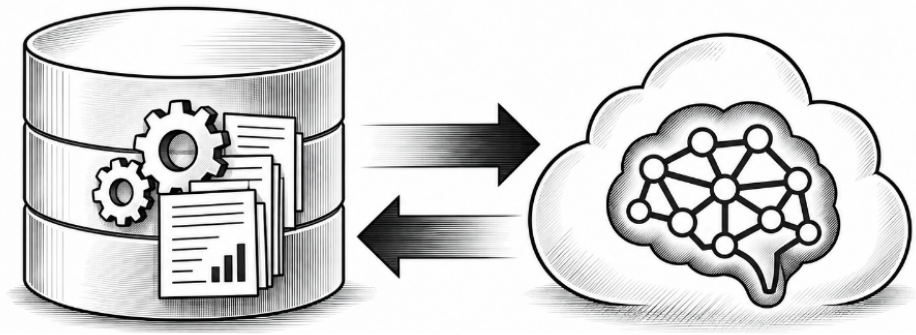

DB：ツール実行と履歴

クラウド：判断するLLM

アイ
基盤はDBの中。
LLMへ渡す指示・ツール定義・結果の内容も設計します。

検査を入れる前の試作：未呼出し

「契約を確認しました」と答えたのに、ツールを呼んでいません！

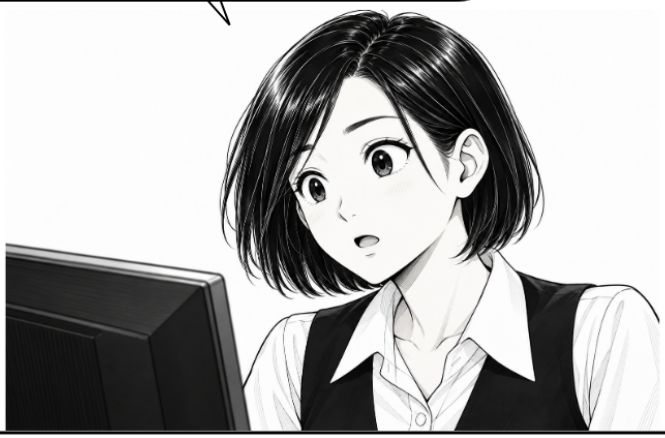

失敗例②：実行エラーを成功扱い

呼んでいても安心できない。実行に失敗したのに、成功したように答えることもある。

失敗例③：呼び出しの引数違い

DEV001の依頼なのに、DEV005を渡していました。結果の機器も違います。

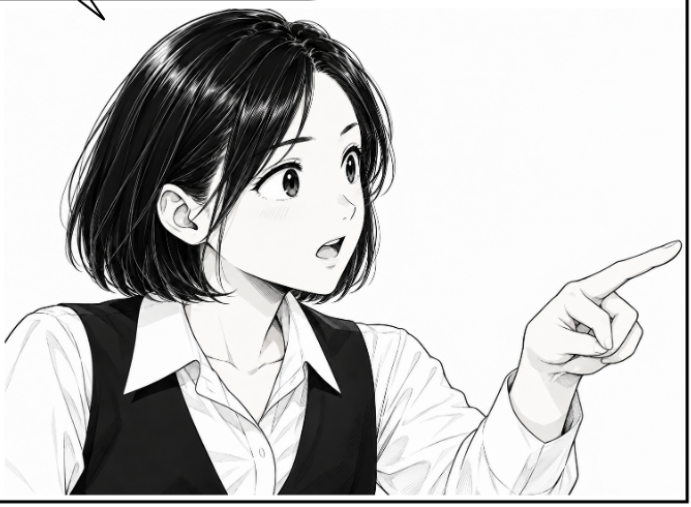

LLMに「実行を確認して」と、もう一度頼めばいいですか？

その確認も間違えることがある。ここもハーネスの仕事だよ。

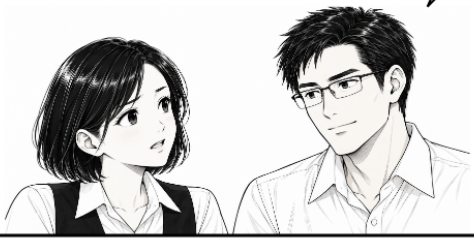

今のチケットをコードで保証する

担当権限を確認した今のチケットから、対象機器をアプリで設定する。不一致はDBで止める。

検索語はLLMに任せても、チケットと対象は勝手に変えさせないんですね。

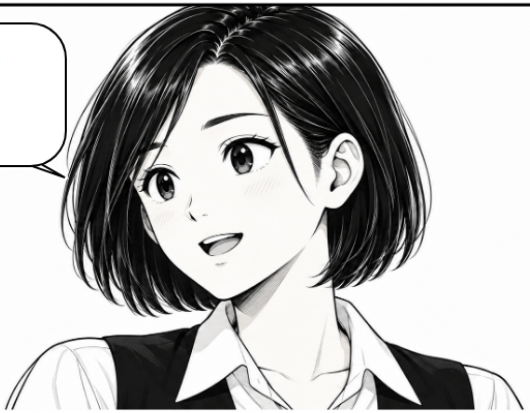

ツールの履歴で実行を確かめる

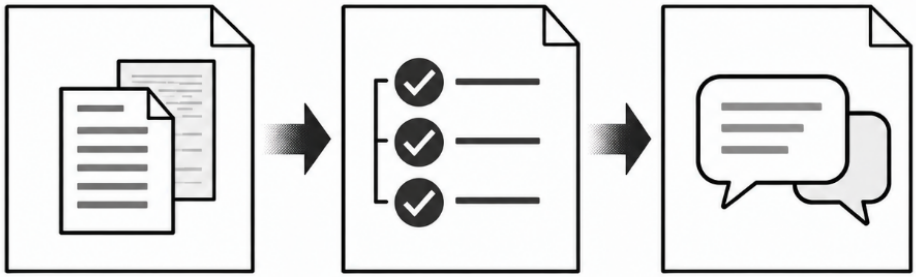

今回の入力と対象　成功した返却内容　回答との照合

神宮寺
Select AI Agentにはツールの呼出履歴を参照するビューがある。記録と返却内容をコードで確かめよう。

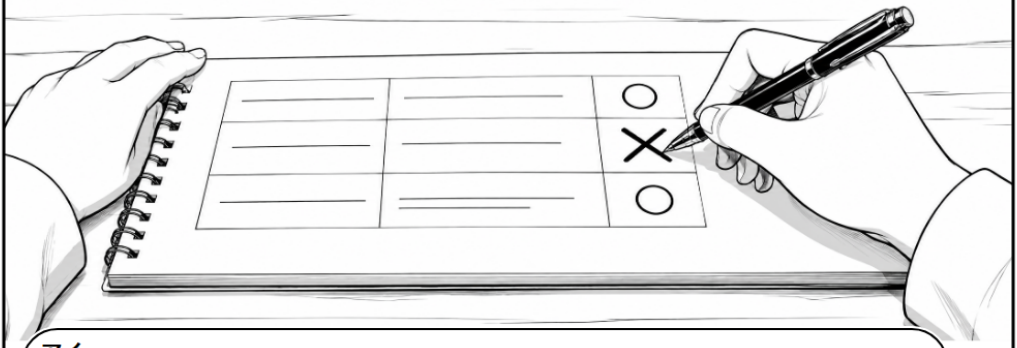

アイ
呼出しなし・実行失敗・対象違いなら、成功した回答として通さない。引用や契約値を照合する検査も用意しました。

検査を加えて、もう一度

KB001：電源・LAN・疎通の確認とログ保存

二つのツールを実行し、
対象も結果も一致しました。
再起動前の影響確認も、回答に残っています。

KB012：顧客内の運用責任者へ連絡

現地保守の対象でも、訪問の確約には担当者の承認が必要です。

対象・承認済み・予約済みは別。画面でも区別しよう。

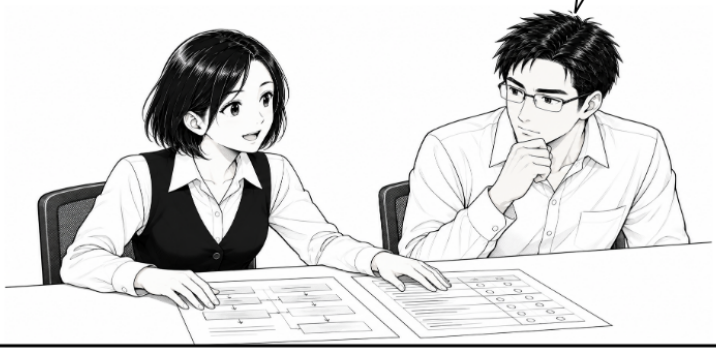

契約判定と訪問承認を分ける

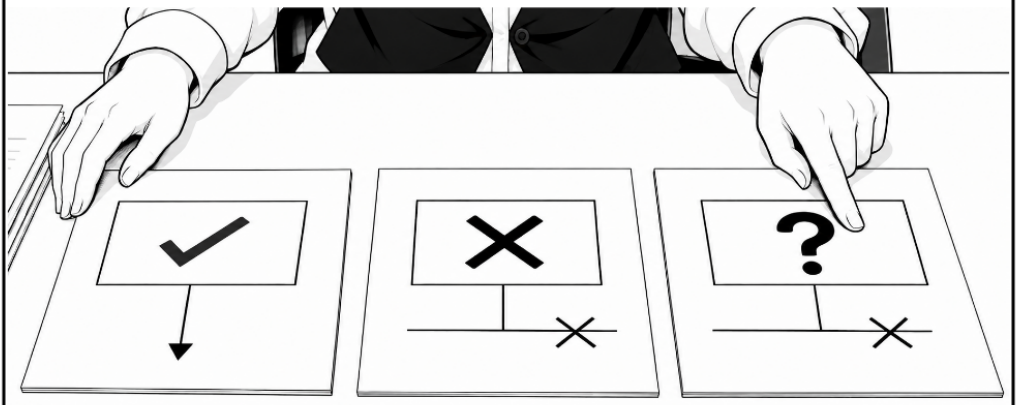

対象：
承認を確認

対象外：
承認へ進めない

不明：
承認へ進めない

アイ
技術手順は閲覧が許可されていれば案内する。ここも分けて検証します。

AIに任せること、コードで守ること

二つの固定SQLツールで、
AgentとSelect AI Agentの
働きがつながりました。

今度は要件に合わせて、必要なツールと、その守り方を設計できるね。

はい。使えるデータ、引数、失敗時の扱いまで含めて。Agentアプリを設計できそうです！

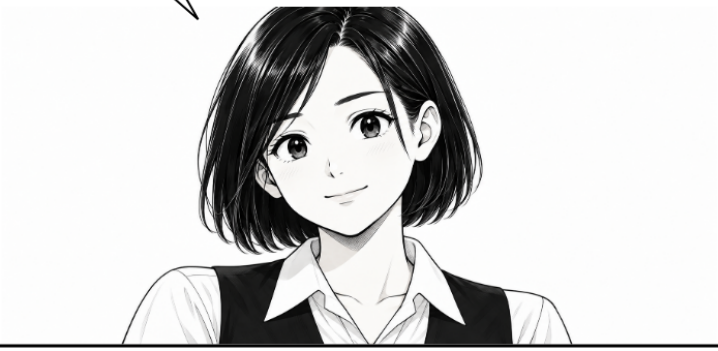

次は、要件に合ったツール群へ

コードと環境準備は原記事のAppendixへ。